神经网络中的「内省」
(“introspection” in neural networks)

甄景贤 (King-Yin Yan)

General.Intelligence@Gmail.com

July 26, 2017

Abstract. 在本文中「内省」是指智能系统直接读 / 写知识的能力，此能力在经典 logic-based AI 是免费做到的，但神经网络内的「知识」素来有「黑盒」的问题。解决办法是让神经网络直接作用在它自身的 weights 上。

0 Introduction

这篇文章说的「内省」的意思是指智能系统有能力读 / 写它内部的知识。例如说，一个比较蠢的智能系统可以用 sequence-to-sequence 的方式将中文翻译成英文：

$$\text{“}\boxed{\text{中文句子}}\text{”} \xrightarrow{\boldsymbol{F}} \text{“}\boxed{\text{英文句子}}\text{”} \tag{1}$$

$\boldsymbol{F}$ 代表系统的函数。但系统并不真的明白句子的意义，句子只是「水过鸭背」地流过系统。一个更聪明的系统是：句子可以**进入**到 $\boldsymbol{F}$ 里。我所说的「内省」就是这意思。

「内省」亦有 meta-reasoning 的意思，亦即除了**外在**的知识，系统还拥有关於系统**自身状态**的知识。但本文中「内省」是指存取「普通知识」的能力。

1 Applications

Introspection (in the present paper’s sense) is useful in:

- learning by instructions, or “learn by being told”
  (a technique crucial to accelearating the learning of human knowledge)
- belief revision / truth maintenance
  (the most challenging and highest-level task in logic-based AI)

举例来说，小孩子的行为是由他内部的知识决定的，「知识决定行为」。

- 当小孩子看到一个成人做的动作，他会模仿那动作。

(2)

- 或者小孩子听到一句说话：「不要吃污糟食物」，他明白了那句说话的意思而改变行为。

这两个例子都涉及到将「感觉资料」放进 $\boldsymbol{F}$ 里面：

$$\boxed{\text{sensory data}} \hookrightarrow \boldsymbol{F} \tag{3}$$

2 Cartesian closure

Introspection requires the functional closure $\mathbb{X} \simeq \mathbb{X}^{\mathbb{X}}$ which yields a **Cartesian-closed category** (CCC).

举例来说，「吃了污糟的食物会肚痛」是一个句子，它经由 进入 mental state $\boldsymbol{x}$ ，变成 proposition。但我们希望这逻辑命题变成 的一部分。$\boldsymbol{F}$ is the state-transition function:

$$\boldsymbol{x}_{n+1} = \boldsymbol{F}(\boldsymbol{x}_n) \tag{4}$$

where

$$\boldsymbol{F} = \quad = $$
$$\boldsymbol{x} = \text{state}$$

An individual logic rule is a restriction of $\boldsymbol{F}$ to a specific input; Perhaps I could call such elements "micro-functions".

$\boldsymbol{F} \equiv$ is the "union" of micro-functions:

$$ = \bigcup \boldsymbol{f}_i \tag{5}$$

Or, in a vague sense, $\boldsymbol{F}$ is the sum total of objects like $\boldsymbol{x}$:

$$\boldsymbol{F} = \bigcup \boldsymbol{x}_i \tag{6}$$

但 $\boldsymbol{F}$ 是一个神经网络，它的一般形式是：

$$\boxed{\text{output}}\ \boldsymbol{x}_{n+1} = \boldsymbol{F}(\boldsymbol{x}_n) = \overset{1}{W} \quad \overset{2}{W} \ \ldots\ldots \ \overset{L}{W} \ \boldsymbol{x}_n \tag{7}$$

L = total number of layers. 由於各层的非线性「纠缠在一起」，表面上无法将神经网络「分解」。直到笔者受了 David Ha *et al* 提出的 PathNet [1] 理论所启发，PathNet 是由一些较小的神经网络 modules 组成，所以或许可以建构如下形式的「丝状神经网络」:

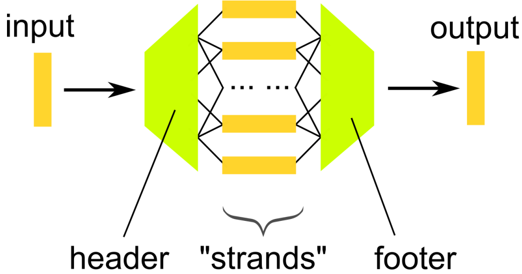

(8)

这些「丝条 」可以是简单的神经网络，例如每个的宽度或深度很小，因而可以用较短的 weights vector 描述。正是因为这原因，一个 本身可以作为神经网络的输入。但整个神经网络 $\boldsymbol{F}$ 无法输入自己，因为根据 Cantor's theorem，$\mathbb{X} = \mathbb{X}^{\mathbb{X}}$ 是不可能的。

Let $\overline{\boldsymbol{F}}$ = header, $\underline{\boldsymbol{F}}$ = footer, $\boldsymbol{f}_i$ = strands, then (abusing the $\bigcup$ notation):

$$\boldsymbol{F} = \overline{\boldsymbol{F}} \circ \bigcup \boldsymbol{f}_i \circ \underline{\boldsymbol{F}} \tag{9}$$

每个 大约对应於逻辑上的一个**命题**（proposition, 可以是条件命题或普通命题）。

3 Structure of memories

The "main memory" $\boldsymbol{F}$ can take the form of a tree ( ), graph ( ), or hyper-graph ( ), with increasing complexity.

The **mental state** $\boldsymbol{x}$, or "working memory", can also assume the above-mentioned forms.

Currently I am not sure whether to place **episodic memory** inside $\boldsymbol{F}$ or as a separate module outside $\boldsymbol{F}$.

We need to organize the 's in the form of , or , in such a way that the resulting structure is also a neural network, or more generally a mathematical **function** in Hilbert space.

But there is one simple way: Basically, a deep network is automatically "tree-like" because of its many layers (**levels**) of weights organized hierarchically. Thus we can build a network like this:

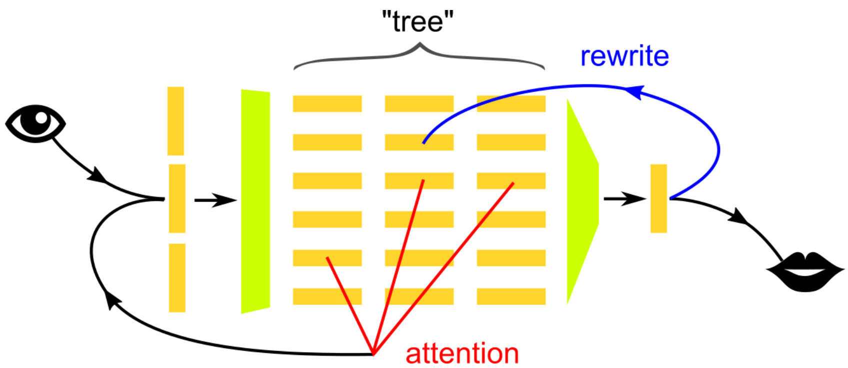

(10)

The attention mechanism selects a number of 's to be the **current state** or "working memory". Notice that the input size is bigger than the output size, which reflects the structure of the logical **consequece operator** $\vdash$.

4 Overall architecture

For reference, the architecture for **visual recognition** is:

 (11)

Our basic AGI architecture is:

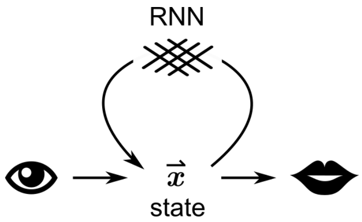

(12)

 = [deep] neural network, trained via **reinforcement learning**

The overall **recurrent** setup operates like this:

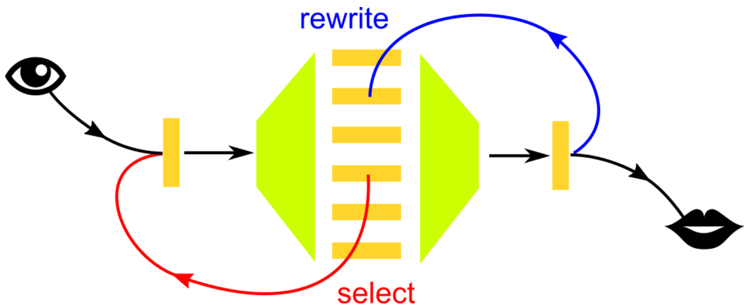

(13)

Viewing the “information flow” in a simplified way, we notice a “second” pass through the network’s internal weights:

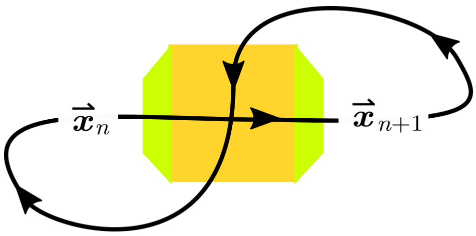

(14)

这种操作上的结构在经典逻辑 AI 是「免费赠品」，但似乎还未有人提出过神经网络的做法。

对应於经典逻辑 AI：

 = KB (15)

- The **horizontal pass** represents using the KB for logical inference (thinking), ie:

$$\boldsymbol{x}_n \cup \text{KB} \vdash \boldsymbol{x}_{n+1} \tag{16}$$

- The **vertical pass** represents reading/writing information to/from KB. It performs 2 operations:
  - $\boldsymbol{x}$ = working memory 会因为 **注意力** (attention) 而改变，所以 $\boldsymbol{x}_{n+1}$ 并不直接进入下一轮的 iteration，而是先经过 KB 的 attentional change。
  - $\boldsymbol{x}$ 是 KB 的一部分，所以 $\boldsymbol{x}_{n+1}$ 改变了，KB 也要 update。

5 几何结构

[此段对熟悉微分几何的人或许有帮助，否则可以略过。]

首先我们有一个很 standard 的 Hamiltonian 力学系统 / 控制系统的结构：

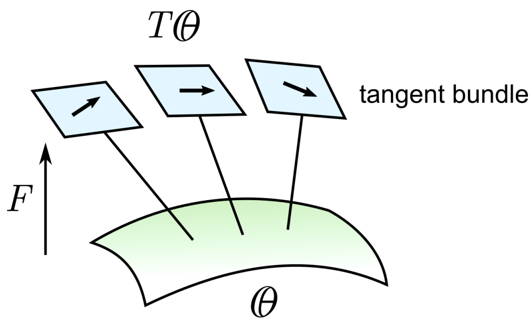

(17)

$\boldsymbol{x}$ = working memory $\subset \boldsymbol{\theta}$，$\boldsymbol{\theta}$ 代表整个 KB 的状态，而 $\boldsymbol{\theta} \in \mathit{\Theta}$，后者是所有可能 KB 的空间。

$$\dot{\boldsymbol{x}} = \boldsymbol{F}(\boldsymbol{x}) \tag{18}$$

是系统的**状态方程**。换句话说，在思维空间 $\mathit{\Theta}$ 中的一个点就是思维状态 $\boldsymbol{x} \subset \boldsymbol{\theta} \in \mathit{\Theta}$，而 F 给出的是这个点在**思考**过程中的的「运动速度」$= \dot{\boldsymbol{x}}$。换句话说，$\boldsymbol{F}$ 定义了一个 vector field，它是思维空间中思维的 “flow”，或者可以叫作「理性流」。每个点的速度属於流形 $\mathit{\Theta}$ 上的 tangent space，他们的总和就是 tangent bundle。而 tangent bundle + base manifold（亦即「位置 & 动量」）构成系统的「相空间」(phase space)。

另外，特别地，有这个 sheaf of functions 的结构：

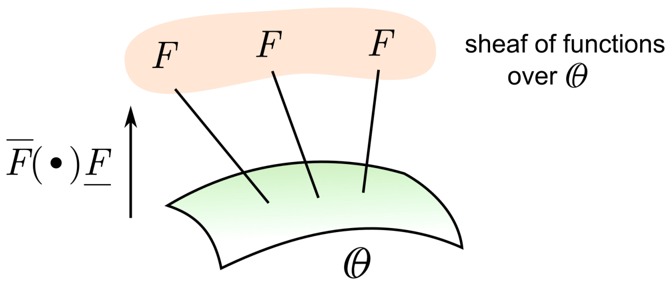

(19)

换句话说，给定 $\boldsymbol{x} \in \mathit{\Theta}$ ，我们可以透过

$$\boldsymbol{F} = \overline{\boldsymbol{F}} \circ (\boldsymbol{x} \subset \boldsymbol{\theta}) \circ \underline{\boldsymbol{F}} \tag{20}$$

得出 $\boldsymbol{F}$，而这个 $\boldsymbol{F}$ 再给出对应於这点的 $\dot{\boldsymbol{x}}$。

注意 (17) 和 (19) 是两个不同的结构，只是它们的 base manifold 相同。

特别之处在於 $\boldsymbol{F}$ 是由参数 $\boldsymbol{x} \subset \boldsymbol{\theta} \in \mathit{\Theta}$ 确定的（因为 $\boldsymbol{x}$ 是 $\boldsymbol{\theta} =$ KB 的一部分，而所有可能的 KB 属於思维空间 $\mathit{\Theta}$ ），换句话说：

$$\boldsymbol{F}(\boldsymbol{x}) \equiv \boldsymbol{F}_{\boldsymbol{\theta}}(\boldsymbol{x}) \equiv \boldsymbol{F}(\boldsymbol{x}; \boldsymbol{\theta}) \tag{21}$$

这和经典理论并没有抵触，因为经典理论中，$\boldsymbol{F}$ 也是位置 $\boldsymbol{x}$ 的函数。更确切地说，位置空间其实是由 $\boldsymbol{\theta} \in \mathit{\Theta}$ 决定的，$\boldsymbol{x}$ 只是 $\boldsymbol{\theta}$ 的一部分。

6 Conclusion

Using the "introspective architecture" we solved 2 major problems in AGI:

- How to directly **insert** knowledge into KB.
- KB should be organized as a graph / tree. But KB is also a neural network. We found a "tree-like" organization of KB as a neural network.

It seems that the only major remaining problem now is the design of **episodic memory**.

Acknowledgements

Thanks to David Ha for his PathNet idea.

Bibliography

[1] Chrisantha Fernando, Dylan Banarse, Charles Blundell, Yori Zwols, David Ha, Andrei A. Rusu, Alexander Pritzel, and Daan Wierstra. Pathnet: Evolution channels gradient descent in super neural networks. *CoRR*, abs/1701.08734, 2017. URL `http://arxiv.org/abs/1701.08734`.